

Drug Response Prediction – GDSC1

1. Αρχιτεκτονική Συστήματος

Το προτεινόμενο μοντέλο είναι σχεδιασμένο για την πρόβλεψη της ευαισθησίας καρκινικών κυτταρικών σειρών σε φαρμακευτικές ενώσεις (Drug Response) στο dataset **GDSC1**.

Η βασική ιδέα είναι ότι:

- η **χημική πληροφορία του φαρμάκου**
- και το **βιολογικό προφίλ της κυτταρικής σειράς**

επεξεργάζονται **ξεχωριστά**, προβάλλονται σε έναν **κοινό λανθάνοντα χώρο**, και στη συνέχεια **συνδυάζονται** για την τελική πρόβλεψη.

2. Αναπαράσταση Δεδομένων Εισόδου

A. Drugs

SMILES αναπαραστάσεις φαρμάκων από το GDSC1

Featurization:

Morgan Fingerprints (ECFP4)

Παράμετροι:

- Ακτίνα (radius): 2
- Διαστάσεις: 2048 bits

B. Cells

Gene Expression δεδομένα (RNA-seq)

Αρχική διάσταση: ~17.737 γονίδια

Μείωση διάστασης:

- Επιλογή των **1000 γονιδίων με τη μεγαλύτερη διακύμανση** (variance-based feature selection)


Κανονικοποίηση:

- Standardization (mean = 0, std = 1), υπολογισμένη **μόνο στο training set**


Η επιλογή υψηλής διακύμανσης γονιδίων επιτρέπει στο μοντέλο να εστιάσει σε βιολογικά σήματα που διαφοροποιούν τις κυτταρικές σειρές και σχετίζονται με τη φαρμακευτική απόκριση.

3. MLP encoders

Drugs



Cells



A. Drug Encoder

Δομή:

1. Linear(2048 $\rightarrow$ 256)
2. Batch Normalization
3. ReLU
4. Dropout(p = 0.4)
5. Linear(256 $\rightarrow$ 128)
6. Batch Normalization
7. ReLU
8. Dropout(p = 0.4)

Έξοδος: $Z_{drug} \in \mathbb{R}^{128}$


B. Cells Encoder

Δομή:

1. **Linear(1000 $\rightarrow$ 256)**
2. **Batch Normalization**
3. **ReLU**
4. **Dropout(p = 0.4)**
5. **Linear(256 $\rightarrow$ 128)**
6. **Batch Normalization**
7. **ReLU**
8. **Dropout(p = 0.4)**

Έξοδος: $Z_{cell} \in \mathbb{R}^{128}$

C. Fusion & Regression Head



Regression Head:

1. Linear($256 \rightarrow 128$)
2. ReLU
3. Linear($128 \rightarrow 1$)

Έξοδος: $\hat{y} \in \mathbb{R}$

Η έξοδος αντιστοιχεί στην προβλεπόμενη τιμή **IC50**, δηλαδή την ευαισθησία της κυτταρικής σειράς στο φάρμακο.

4. Υπερπαράμετροι Εκπαίδευσης (Configuration)

Οι τελικές υπερπαράμετροι του μοντέλου ορίζονται ως εξής:

Πειραματικές Ρυθμίσεις

- `run_tag: "optimized_regularized_lr_scheduler"`
- `dataset: GDSC1`

Χαρακτηριστικά Εισόδου

- `ecfp_bits: 2048`
- `ecfp_radius: 2`

Διαστάσεις Μοντέλου

- `z_dim: 128`
- `drug_hidden: 256`
- `cell_hidden: 256`
- `dropout: 0.4`

Εκπαίδευση

- `batch_size: 128`
- `learning_rate:  $5 \times 10^{-4}$`
- `weight_decay:  $1 \times 10^{-4}$`
- `epochs: 50`
- `validation_split: 10%`

Early Stopping

- `patience: 8 epochs`
- `min_delta:  $1 \times 10^{-4}$`

Runtime

- `device: GPU (CUDA) αν διαθέσιμο, αλλιώς CPU`
- `num_workers: 4`

5. Μεθοδολογία & Βελτιστοποίηση

Το μοντέλο εξελίχθηκε από ένα απλό baseline (RMSE ≈ 1.34) σε ένα **state-of-the-art baseline** μέσω:


1. Δραστικής μείωσης διάστασης στα βιολογικά δεδομένα
2. Κλιμάκωσης στο πλήρες dataset (~177k δείγματα)
3. Ισχυρής κανονικοποίησης (BatchNorm + Dropout 0.4)
4. Learning Rate Scheduler (ReduceLROnPlateau) για σταθερή σύγκλιση

6. Τελική Απόδοση Μοντέλου


- **Dataset:** GDSC1 (177,310 drug–cell interactions)
- **RMSE (Validation): 0.9487**
- **Pearson Correlation (r): 0.9368**

Plots


Train / Validation Loss vs Epoch



Validation RMSE vs Epoch



Validation Pearson Correlation vs Epoch



Predicted vs True

